

第二章、多元正态分布及参数的估计

September 25, 2018

2.0 引入

1. 多元统计的主要研究内容

分类（判别分析），建模（多元回归，变量选择），降维（公因子，压缩惩罚），典型相关分析（组间）

2. 多元数据的直觉

两两之间的关系（ACF, 散点图），轮廓图，雷达图

3. 多元分析的理论基础

数据的估计与推断离不开理论的支撑，这就要求数据分布有一定的假设

一、随机向量的联合分布,边缘分布,条件分布

1. 多元数据

a. 随机向量：若 X_i 都为随机变量，则

称 $\mathbf{X} = (X_1, \dots, X_p)'$ 为 p 维随机向量。

b. 随机矩阵： $\mathbf{X}_{n \times p} = (\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n)'$ ，其中 \mathbf{X}_i 为 p 维随机向量。

2. 多元分布

(i) 分布函数： $F(\mathbf{X} \leq \mathbf{x}) = P(X_1 \leq x_1, \dots, X_p \leq x_p)$ ， $\mathbf{x} = (x_1, \dots, x_p)' \in \mathcal{R}^p$ 为 \mathbf{X} 。

(ii) 密度函数: 设 $F(\mathbf{x})$ 为 \mathbf{X} 的分布函数, 若存在非负函数 $f(\mathbf{x})$, 使得对任意 $\mathbf{x} \in \mathcal{R}^p$, 都有

$$F(\mathbf{x}) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} \cdots \int_{-\infty}^{x_p} f(x_1, x_2, \dots, x_p) dx_1 dx_2 \cdots dx_p,$$

则称 $f(\mathbf{x})$ 为 \mathbf{X} 的密度函数。

3. 边际分布

设 $F(\mathbf{x})$ 为 \mathbf{X} 的分布函数, $\mathbf{X}_1 = (X_{i_1}, \dots, X_{i_q})'$, $q < p$ 为 \mathbf{X} 的子向量。则对任意 $\mathbf{x}_1 = (x_{i_1}, \dots, x_{i_q})'$,

$$P(\mathbf{X}_1 \leq \mathbf{x}_1) = F(\infty, \dots, x_{i_1}, \infty, \dots, x_{i_q}, \dots, \infty).$$

4. 条件分布

设 $\mathbf{X} = (\mathbf{X}'_1, \mathbf{X}'_2)'$, 则在给定 \mathbf{X}_2 条件下, \mathbf{X}_1 的条件分布为

$$f(\mathbf{x}_1|\mathbf{x}_2) = f(\mathbf{x}_1, \mathbf{x}_2)/f_{X_2}(\mathbf{x}_2).$$

5. 相互独立

设 $(\mathbf{X}'_1, \mathbf{X}'_2)'$ 的联合密度函数, 与边际密度函数满足:

$$f(\mathbf{x}_1, \mathbf{x}_2) = f_{x_1}(\mathbf{x}_1)f_{x_2}(\mathbf{x}_2).$$

进一步, 若

$$f(\mathbf{x}) = \prod_{i=1}^p f_i(x_i),$$

则称 X_1, \dots, X_p 相互独立。

二、随机向量的数字特征

设 $X = (X_1, \dots, X_p)'$, $Y = (Y_1, \dots, Y_q)'$ 是两个随机向量.

1、随机向量 X 的均值向量

$$E(X) = [E(X_1), \dots, E(X_p)]' = (\mu_1, \dots, \mu_p)'$$

2、随机向量 X 的协方差阵

$$D(X) = E[(X - E(X))(X - E(X))'] = (\sigma_{ij})_{(p \times p)} \stackrel{\text{def}}{=} \Sigma$$

3、随机向量 X 和 Y 的协方差阵

$$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))'] = (\sigma_{ij})_{(p \times q)}$$

如果 $\text{Cov}(X, Y) = 0$, 则称 X 和 Y 是不相关的.

$\rho = (\rho_{ij})_{(p \times p)}$ 为 X 的**相关（系数矩）阵**, 其中

$$\rho_{ij} = \frac{\text{Cov}(X_i, X_j)}{\sqrt{\text{Var}(X_i)\text{Var}(X_j)}} = \frac{\sigma_{ij}}{\sqrt{\sigma_{ii}\sigma_{jj}}} (i, j = 1, \dots, p)$$

若记 $V^{1/2} = \text{diag}(\sqrt{\sigma_{11}}, \dots, \sqrt{\sigma_{pp}})$ 为**标准差矩阵**, 协方差矩阵和相关阵的关系如下,

$$\rho = V^{-1/2} \Sigma V^{-1/2}$$

或

$$\Sigma = V^{1/2} \rho V^{1/2}$$

其中: $V^{-1/2} = (V^{1/2})^{-1} = \text{diag}(1/\sqrt{\sigma_{11}}, \dots, 1/\sqrt{\sigma_{pp}})$.

三、均值向量和协方差阵性质

性质1 设 X 和 Y 是随机向量, A, B 是常数矩阵,则

$$E(AX) = AE(X)$$

$$E(AXB) = AE(X)B$$

$$\text{Var}(AX) = A\text{Var}(X)A'$$

$$\text{Cov}(AX, BY) = A\text{Cov}(X, Y)B'.$$

性质2 若 X 和 Y 相互独立,则 $\text{Cov}(X, Y) = 0$,反之未必成立.

性质3 随机向量 $X = (X_1, \dots, X_p)$ 的协方差矩阵 $\text{Var}(X) = \Sigma$ 是对称非负定矩阵.

性质4 $\Sigma = L^2$, 其中 L 为非负定矩阵. 特别当 $\Sigma > 0$ 时, $L > 0$. 矩阵 L 也称为矩阵 Σ 的平方根矩阵.

例1: 已知 $\mathbf{X} = (X_1, X_2)'$, $E\mathbf{X} = (\mu_1, \mu_2)'$,

$\text{Cov}\mathbf{X} = \begin{pmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{pmatrix}$. 求 $Y_1 = 2X_1 - X_2$, $Y_2 = X_1 + X_2$ 的均

值向量和协方差阵?

2.2 多元正态分布的定义与基本性质

注意：多元正态分布的四种等价定义.

定义2.2.1 设 $U = (U_1, U_2, \dots, U_q)'$ 为随机向量, U_1, \dots, U_q 相互独立且同 $N(0, 1)$ 分布, 设 μ 为 p 维常数向量, A 为 $p \times q$ 常数矩阵, 则称 $X = AU + \mu$ 的分布为 p 元正态分布, 或称 X 为 p 维正态随机向量, 记为 $X \sim N_p(\mu, AA')$.

性质1 设 $U = (U_1, U_2, \dots, U_q)'$ 为随机向量, U_1, \dots, U_q 相互独立且同 $N(0, 1)$ 分布, 则 $X = AU + \mu$ 的特征函数为

$$\Phi_X(t) = \exp \left[it' \mu - \frac{1}{2} t' A A' t \right]$$

其中 $t = (t_1, \dots, t_p)' \in \mathbb{R}^p$.

由概率论知识,

- 标准正态分布的特征函数,

$$\Phi_{U_i}(t_i) = \exp \left[-\frac{1}{2} t_i^2 \right].$$

- 随机向量 X 的特征函数,

$$\Phi_X(t) = \exp [it' X].$$

其中 $t = (t_1, \dots, t_p)' \in \mathbb{R}^p$.

定义2.2.2 若 p 维随机向量 X 的特征函数为

$$\Phi_X(t) = \exp \left[it' \mu - \frac{1}{2} t' \Sigma t \right]$$

则称 X 服从 p 元正态分布,记为 $X \sim N_p(\mu, \Sigma)$

性质2 设 $X \sim N_p(\mu, \Sigma)$, B 为 $s \times p$ 常数矩阵, d 为 s 维常数向量, 令 $Z = BX + d$, 则 $Z \sim N_s(B\mu + d, B\Sigma B')$.

性质2指出正态随机向量的任意线性变换仍服从正态分布.

推论 设 $X = \begin{bmatrix} X^{(1)} \\ X^{(2)} \end{bmatrix} \begin{matrix} r \\ p-r \end{matrix} \sim N_p(\mu, \Sigma)$, 将 μ, Σ 剖分为

$$\mu = \begin{bmatrix} \mu^{(1)} \\ \mu^{(2)} \end{bmatrix} \begin{matrix} r \\ p-r \end{matrix}, \Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \begin{matrix} r \\ p-r \end{matrix}$$

则 $X^{(1)} \sim N_r(\mu^{(1)}, \Sigma_{11})$, $X^{(2)} \sim N_{p-r}(\mu^{(2)}, \Sigma_{22})$.

性质3 若 $X \sim N_p(\mu, \Sigma)$, 则 $E(X) = \mu, \text{Var}(X) = \Sigma$

性质4 设 $X = (X_1, X_2, \dots, X_p)'$ 为 p 维随机向量, 则 X 服从 p 元正态分布 \iff 对任一 p 维实向量 a , (a 为非零向量), $\xi = a'X$ 是一维正态随机变量.

(利用特征函数来证明)

定义2.2.3 若 p 维随机向量 X 的任意线性组合 $a'X$ (a 为非零向量)均服从一元正态分布, 则称 X 为 p 维正态随机向量.

性质5 若 $X \sim N_p(\mu, \Sigma)$, 且 $\Sigma > 0$ (正定), 则 X 的联合密度函数是

$$f(x) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (x - \mu)' \Sigma^{-1} (x - \mu) \right]$$

- 多元标准正态随机变量 $U = (U_1, U_2, \dots, U_q)'$ 的密度函数, 记: $u = (u_1, \dots, u_q)$,

$$f(u) = (2\pi)^{-\frac{q}{2}} \prod_{i=1}^q \exp\{-\frac{1}{2} u_i^2\} = (2\pi)^{-\frac{q}{2}} \exp\{-\frac{1}{2} u' u\}.$$

- 多元正态随机变量 $X = AU + \mu$, 采用积分变换, 记Jacobian行列式为 $J(u \rightarrow x)$, 由 U 的密度函数, 得出 X 的密度函数.

$$f(x) = f(u(A^{-1}(x - \mu))) J(u \rightarrow x),$$

其中

$$J(u \rightarrow x) = |AA'|^{1/2} = |\Sigma|^{1/2}.$$

定义2.2.4 若 p 维随机向量 X 的联合密度函数为

$$f(x) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (x - \mu)' \Sigma^{-1} (x - \mu) \right]$$

其中 μ 为 p 维常数向量, Σ 是 p 阶正定矩阵; 也称 X 为 p 维正态随机向量.

注意: 定义2.2.4 要求 $\Sigma > 0$, 但前面三种定义只要求 $\Sigma \geq 0$.

例2、(二元正态分布密度函数): 设 $X = (X_1, X_2) \sim N_2(\mu, \Sigma)$, 则

$$\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix} = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix},$$

$$\Sigma^{-1} = \frac{1}{\sigma_1^2\sigma_2^2(1-\rho^2)} \begin{bmatrix} \sigma_1^2 & -\rho\sigma_1\sigma_2 \\ -\rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}.$$

代入

$$f(x) = \frac{1}{(2\pi)^{p/2}|\Sigma|^{1/2}} \exp \left[-\frac{1}{2}(x - \mu)' \Sigma^{-1}(x - \mu) \right]$$

得二元正态分布密度函数。

二元正态密度函数图： 绘制二元正态密度函数的图形及其相应的等高线图形. R中的graphics包中的persp函数用于作3D图形


```
(一) 赋值
mu1<-0; mu2<-0; s11<-10; s12<-15; s22<-10; rho<-0.5;
x1<-seq(-10,10,length=41) # generating the vector series x1
x2<-x1 # copying x1 to x2

(二) 写出密度函数
f<-function(x1,x2)
{
  term1<-1/(2*pi*sqrt(s11*s22*(1-rho^2)))
  term2<--1/(2*(1-rho^2))
  term3<-(x1-mu1)^2/s11
  term4<-(x2-mu2)^2/s22
  term5<--2*rho*((x1-mu1)*(x2-mu2))/(sqrt(s11)*sqrt(s22))
  2
  term1*exp(term2*(term3+term4-term5))
}

(三) 计算密度函数值
z<-outer(x1,x2,f) # calculating the density values

(四) 作图
persp(x1, x2, z)
```

Two dimensional Normal Distribution

 $\mu_1 = 0, \mu_2 = 0, \sigma_{11} = 10, \sigma_{22} = 10, \sigma_{12} = 15, \rho = 0.5$


$$f(\mathbf{x}) = \frac{1}{2\pi\sqrt{\sigma_{11}\sigma_{22}(1-\rho^2)}} \cdot \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x_1-\mu_1)^2}{\sigma_{11}} - 2\rho\frac{x_1-\mu_1}{\sqrt{\sigma_{11}}}\frac{x_2-\mu_2}{\sqrt{\sigma_{22}}} + \frac{(x_2-\mu_2)^2}{\sigma_{22}}\right]\right\}$$

等高面： 称 $\{\mathbf{x} : f(\mathbf{x}) = c\}$ 为 \mathbf{X} 的等高面，等价于


$$\{\mathbf{x} : (\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) = d\}.$$

特别地，当 \mathbf{X} 为二维正态随机变量时， $f(\mathbf{x}) = c$ 等价于

$$\left(\frac{x_1 - \mu_1}{\sigma_1}\right)^2 - 2\rho \left(\frac{x_1 - \mu_1}{\sigma_1}\right) \left(\frac{x_2 - \mu_2}{\sigma_2}\right) + \left(\frac{x_2 - \mu_2}{\sigma_2}\right)^2 = d(1 - \rho^2),$$

其中， $\rho = \text{Cov}(X_1, X_2)$.

R中的graphics包中的contour函数。 例如，`contour(x1, x2, z)`可得下面图形。



2.3 条件分布和独立性

注意：本节讨论的 $\Sigma > 0$ 的情形.

一、独立性

定理2.3.1 若 p 维随机向量 $X \sim N_p(\mu, \Sigma)$

$$X = \begin{bmatrix} X^{(1)} \\ X^{(2)} \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu^{(1)} \\ \mu^{(2)} \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right)$$

则

$X^{(1)}$ 与 $X^{(2)}$ 独立 $\iff \Sigma_{12} = \mathbf{0}$ 即 $X^{(1)}$ 与 $X^{(2)}$ 互不相关.

证明思想:

⇒ 独立推出不相关, 即 $\Sigma_{12} = \mathbf{0}$;

⇐ $\Sigma_{12} = \mathbf{0}$, 由此推出, 联合密度等边际密度的乘积.

$$\begin{aligned} & f(x^{(1)}, x^{(2)}) \\ &= \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (x - \mu)' \begin{bmatrix} \Sigma_{11} & 0 \\ 0 & \Sigma_{22} \end{bmatrix}^{-1} (x - \mu) \right] \\ &= f_1(x^{(1)}) f_2(x^{(2)}). \end{aligned}$$

推论1 设 $r_i \geq 0 (i = 1, \dots, k)$, 且 $r_1 + r_2 + \dots + r_k = p$, 有

$$X = \begin{bmatrix} X^{(1)} \\ \vdots \\ X^{(k)} \end{bmatrix} \begin{matrix} r_1 \\ \vdots \\ r_k \end{matrix} \sim N_p \left(\begin{bmatrix} \mu^{(1)} \\ \vdots \\ \mu^{(k)} \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \cdots & \Sigma_{1k} \\ \vdots & & \vdots \\ \Sigma_{k1} & \cdots & \Sigma_{kk} \end{bmatrix}_{p \times p} \right)$$

则 $X^{(1)}, \dots, X^{(k)}$ 相互独立 $\iff \Sigma_{ij} = 0$ (一切 $i \neq j$).

推论2 设 $X = (X_1, \dots, X_p)' \sim N_p(\mu, \Sigma)$, 若 Σ 为对角阵, 则 X_1, \dots, X_p 相互独立.

$$X = \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu_1 \\ \vdots \\ \mu_p \end{bmatrix}, \begin{bmatrix} \sigma_{11} & \cdots & 0 \\ \vdots & \sigma_{ii} & \vdots \\ 0 & \cdots & \sigma_{pp} \end{bmatrix} \right)$$

例3、设三维随机向量 $\mathbf{X} \sim N_3(\mu, 2I_3)$, $\mu = (2, 0, 0)'$,

$$A = \begin{pmatrix} 0.5 & -1 & 0.5 \\ -0.5 & 0 & -0.5 \end{pmatrix}, d = \begin{pmatrix} 1 \\ 2 \end{pmatrix}.$$

试求 $Y = A\mathbf{X} + d$ 的分布?

例4、设 $(X_1, X_2, X_3)' \sim N_3(\mu, \Sigma)$, $\mu = (2, -3, 1)'$,

$$\Sigma = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 3 & 2 \\ 1 & 2 & 2 \end{pmatrix}.$$

(1) 试求 $3X_1 - X_2 + 2X_3$ 的分布;

(2) 求二维向量 $a = (a_1, a_2)'$, 使得 X_3 与 $X_3 - a'(X_1, X_2)'$ 相互独立。

二、条件分布

首先考虑二元正态随机向量 (X_1, X_2) 的条件分布,有条件密度的定义知, 给定 X_2 时, X_1 的条件密度为

$$f_1(x_1|x_2) = \frac{f(x_1, x_2)}{f_2(x_2)}$$

所以可以推得

$$(X_1|X_2 = x_2) \sim N_1 \left(\mu_1 + \rho \frac{\sigma_1}{\sigma_2} (x_2 - \mu_2), \sigma_1^2 (1 - \rho^2) \right)$$

协方差矩阵

$$\Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix},$$

根据分块矩阵求逆公式:

$$\Sigma^{-1} = \begin{bmatrix} \Sigma_{11.2}^{-1} & -\Sigma_{11.2}^{-1}\Sigma_{12}\Sigma_{22}^{-1} \\ -\Sigma_{22}^{-1}\Sigma_{21}\Sigma_{11.2}^{-1} & \Sigma_{22}^{-1} + \Sigma_{22}^{-1}\Sigma_{21}\Sigma_{11.2}^{-1}\Sigma_{12}\Sigma_{22}^{-1} \end{bmatrix}$$

其中:

$$\Sigma_{11.2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}.$$

定理2.3.2 设 $X = \begin{bmatrix} X^{(1)} \\ X^{(2)} \end{bmatrix} \begin{matrix} r \\ p-r \end{matrix} \sim N_p(\mu, \Sigma) (\Sigma > 0)$, 则
当 $X^{(2)} = x^{(2)}$ 给定时, $X^{(1)}$ 的条件分布为

$$(X^{(1)} | X^{(2)} = x^{(2)}) \sim N_r(\mu_{1 \cdot 2}, \Sigma_{11 \cdot 2})$$

其中

$$\begin{aligned} \mu_{1 \cdot 2} &= \mu^{(1)} + \Sigma_{12} \Sigma_{22}^{-1} (x^{(2)} - \mu^{(2)}), \\ \Sigma_{11 \cdot 2} &= \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}. \end{aligned}$$

证明思路:

$$\begin{aligned} Z = \begin{bmatrix} Z^{(1)} \\ Z^{(2)} \end{bmatrix} &= \begin{bmatrix} X^{(1)} - \Sigma_{12}\Sigma_{22}^{-1}X^{(2)} \\ X^{(2)} \end{bmatrix} \\ &= \begin{bmatrix} I_r & -\Sigma_{12}\Sigma_{22}^{-1} \\ O & I_{p-r} \end{bmatrix} \begin{bmatrix} X^{(1)} \\ X^{(2)} \end{bmatrix} \triangleq BX. \end{aligned}$$

由前面的性质,知 Z 的分布为仍为正态分布

$$Z = N_p \left(\begin{bmatrix} \mu^{(1)} - \Sigma_{12}\Sigma_{22}^{-1}\mu^{(2)} \\ \mu^{(2)} \end{bmatrix}, \begin{bmatrix} \Sigma_{11.2} & O \\ O & \Sigma_{22} \end{bmatrix} \right).$$

推论 在定理2.3.2条件下可得:

(1) $X^{(2)}$ 与 $X^{(1)} - \Sigma_{12}\Sigma_{22}^{-1}X^{(2)}$ 相互独立;

(2) $X^{(1)}$ 与 $X^{(2)} - \Sigma_{21}\Sigma_{11}^{-1}X^{(1)}$ 相互独立;

(3) $X^{(2)}|X^{(1)} \sim N_{p-r}(\mu_{2\cdot 1}, \Sigma_{22\cdot 1})$, 其中

$$\mu_{2\cdot 1} = \mu^{(2)} + \Sigma_{21}\Sigma_{11}^{-1}(x^{(1)} - \mu^{(1)}),$$

$$\Sigma_{22\cdot 1} = \Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12}.$$

拓展问题:

假设 $X = \begin{bmatrix} X^{(1)} \\ X^{(2)} \\ X^{(3)} \end{bmatrix} \begin{matrix} r_1 \\ r_2 \\ r_3 \end{matrix} \sim N_p(\mu, \Sigma) (\Sigma > 0)$, 其中

$$\mu = \begin{bmatrix} \mu^{(1)} \\ \mu^{(2)} \\ \mu^{(3)} \end{bmatrix}, \Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} & \Sigma_{13} \\ \Sigma_{21} & \Sigma_{22} & \Sigma_{23} \\ \Sigma_{31} & \Sigma_{32} & \Sigma_{33} \end{bmatrix}$$

- $X^{(1)}|(X^{(2)}, X^{(3)})$ 服从什么分布, 均值向量和协方差矩阵的形式是什么?
- $X^{(2)}|(X^{(1)}, X^{(3)})$ 服从什么分布, 均值向量和协方差矩阵的形式是什么?

三、条件数字特征

1. 条件期望, 回归系数, 偏相关系数

设

$$X = \begin{bmatrix} X^{(1)} \\ X^{(2)} \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu^{(1)} \\ \mu^{(2)} \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right)$$

又已知 $X^{(2)} = x^{(2)}$ 给定时, $X^{(1)}$ 的条件分布为

$$(X^{(1)} | X^{(2)} = x^{(2)}) \sim N_r(\mu_{1.2}, \Sigma_{11.2})$$

称

$$\mu_{1.2} = \mu^{(1)} + \Sigma_{12}\Sigma_{22}^{-1}(x^{(2)} - \mu^{(2)}),$$

为条件期望, 记为 $E(X^{(1)} | X^{(2)} = x^{(2)})$; 并称 $\mu_{1.2}$ 为 $X^{(1)}$ 对 $X^{(2)}$ 的回归, 称 $\Sigma_{12}\Sigma_{22}^{-1} \stackrel{def}{=} B$ 为回归系数.

记

$$\Sigma_{11 \cdot 2} = (\sigma_{ij \cdot r+1, \dots, p})_{r \times r} (i, j = 1, \dots, r).$$

称

$$\rho_{ij \cdot r+1, \dots, p} = \frac{\sigma_{ij \cdot r+1, \dots, p}}{\sqrt{\sigma_{ii \cdot r+1, \dots, p}} \sqrt{\sigma_{jj \cdot r+1, \dots, p}}}$$

为偏相关系数，即当 $X^{(2)} = (X_{r+1}, \dots, X_p)'$ 给定时， X_i 与 X_j ($i, j = 1, 2, \dots, r$) 的偏相关系数。

2.全相关系数

设 $Z = \begin{bmatrix} X \\ Y \end{bmatrix} \sim N_{p+1} \left(\begin{bmatrix} \mu_X \\ \mu_y \end{bmatrix}, \begin{bmatrix} \Sigma_{XX} & \Sigma_{Xy} \\ \Sigma_{yX} & \sigma_{yy} \end{bmatrix} \right)$, 则称

$$R = \left(\frac{\Sigma_{yX} \Sigma_{XX}^{-1} \Sigma_{Xy}}{\sigma_{yy}} \right)^{1/2}$$

为 Y 与 $X = (X_1, \dots, X_p)'$ 的全相关系数.

3.最佳预测

在定理2.3.2条件下,考虑 $r = 1$,

记 $X^{(1)} = Y, g(x^{(2)}) = E(Y|X^{(2)} = x^{(2)})$,则对任意的函数 $\phi(\cdot)$,可以证明:

$$E[(Y - g(x^{(2)}))^2] \leq E[(Y - \phi(x^{(2)}))^2]$$

则在均方差最小的准则下,条件期望 $g(x^{(2)})$ 是对 Y 的最佳预测函数.

2.4 随机阵的正态分布

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} = \begin{bmatrix} X'_{(1)} \\ X'_{(2)} \\ \vdots \\ X'_{(n)} \end{bmatrix} = (X_1, X_2, \cdots, X_p)$$

- $X'_{(i)}$ 是来自 p 元总体的第 i 个观测值, $i = 1, \cdots, n$.
- X_j 是随机向量第 j 个分量的一个样本, $j = 1, \cdots, p$.
- \mathbf{X} 是一个样本观测矩阵, 是一个随机矩阵.

一、拉直运算和克罗内克(Kronecker)积

拉直运算是指将矩阵拉成一个长向量, 通过它来建立矩阵和各量之间的关系. 记

$$\text{Vec}\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} = (x_{11}, \cdots, x_{n1}, \cdots, x_{1p}, \cdots, x_{np})'.$$

2.4 随机阵的正态分布

一、拉直运算和克罗内克(Kronecker)积

相应的,

$$\text{Vec}\mathbf{X}' = \begin{bmatrix} X_{(1)} \\ X_{(2)} \\ \vdots \\ X_{(n)} \end{bmatrix} = (x_{11}, x_{12}, \cdots, x_{n1}, \cdots, x_{np})'.$$

代数中的克罗内克积

矩阵 $A = (a_{ij})$ 和 B 分别为 $n \times p$ 和 $m \times q$ 的矩阵, A 和 B 的克罗内克积 $A \otimes B$ 定义为

$$A \otimes B = (a_{ij}B) = \begin{bmatrix} a_{11}B & \cdots & a_{1p}B \\ \vdots & \vdots & \vdots \\ a_{n1}B & \cdots & a_{np}B \end{bmatrix}$$

$A \otimes B$ 为 $mn \times pq$ 矩阵, 在多元统计中被称为矩阵的直积.

二、随机阵的正态分布

设 $X_{(i)}$ 为来自 p 元正态总体 $N_p(\mu, \Sigma)$ 的简单随机样本(独立同分布), $i = 1, \dots, n$, 随机阵 \mathbf{X} 利用按行拉直运算可知,

$$\text{Vec}(\mathbf{X}') \sim N_{np}(\mathbf{I}_n \otimes \mu, \mathbf{I}_n \otimes \Sigma).$$

$$\mathbf{I}_n \otimes \mu = \begin{bmatrix} \mu \\ \vdots \\ \mu \end{bmatrix}, \quad \mathbf{I}_n \otimes \Sigma = \begin{bmatrix} \Sigma & \cdots & O \\ \vdots & \vdots & \vdots \\ O & \cdots & \Sigma \end{bmatrix}$$

如果随机矩阵 \mathbf{X} 按行拉直后, $\text{Vec}(\mathbf{X}') \sim N_{np}(\mathbf{I}_n \otimes \mu, \mathbf{I}_n \otimes \Sigma)$, 则称 \mathbf{X} 服从矩阵正态分布, 记作

$$\mathbf{X} \sim N_{n \times p}(M, \mathbf{I}_n \otimes \Sigma),$$

其中,

$$M = \begin{bmatrix} \mu_1 & \cdots & \mu_p \\ \vdots & \vdots & \vdots \\ \mu_1 & \cdots & \mu_p \end{bmatrix} = \mathbf{1}_n \mu'.$$

设 $\mathbf{X} \sim N_{n \times p}(M, \mathbf{I}_n \otimes \Sigma)$, A 为 $k \times n$ 常数矩阵, B $q \times p$ 常数矩阵, D 为 $k \times q$ 常数矩阵, 令 $Z = AXB' + D$, 则

$$Z \sim N_{n \times q}(AMB' + D, (AA') \otimes (B\Sigma B')).$$

2.5 多元正态分布的参数估计

考虑 p 元正态总体 $\mathbf{X} \sim N_p(\mu, \Sigma)$, 其观测数据阵为

$$X = \begin{bmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & & \vdots \\ x_{n1} & \cdots & x_{np} \end{bmatrix}$$

(1) $x_{(i)} = (x_{i1}, \cdots, x_{ip})'$ 为随机向量 \mathbf{X} 的第 i 个观察值向量,
 $i = 1, \cdots, n$. 一般假设为简单随机样本.

(2) $x_j = (x_{1j}, \cdots, x_{nj})'$ 为随机向量 \mathbf{X} 的第 j 个分量 X_j 的 n 个观察值, $j = 1, \cdots, p$.

在符号不会混淆的情况下, 有时 $x_{(j)}$ 记为 $X_{(j)}$, x_i 记为 X_i .

$$X = \begin{bmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & & \vdots \\ x_{n1} & \cdots & x_{np} \end{bmatrix} = (X_{(1)}, \dots, X_{(n)})' = \begin{pmatrix} X'_{(1)} \\ \vdots \\ X'_{(n)} \end{pmatrix}.$$

or,

$$X = \begin{bmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & & \vdots \\ x_{n1} & \cdots & x_{np} \end{bmatrix} = (X_1, \dots, X_p).$$

一、多元正态总体样本的基本统计量

(1) 样本均值向量 \bar{X} :

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_{(i)} = (\bar{x}_1, \dots, \bar{x}_p)' = \frac{1}{n} X' \mathbf{1}_n,$$

其中

$$\bar{x}_j = \frac{1}{n} \sum_{\alpha=1}^n x_{\alpha j} \quad (j = 1, 2, \dots, p).$$

(2) 样本离差阵(又称交叉乘积阵) A :

$$\begin{aligned} A &= \sum_{\alpha=1}^n (X_{(\alpha)} - \bar{X})(X_{(\alpha)} - \bar{X})' = X'X - n\bar{X}\bar{X}' \\ &= X'[I_n - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n']X \stackrel{def}{=} (a_{ij})_{p \times p} \end{aligned}$$

其中

$$a_{ij} = \sum_{\alpha=1}^n (x_{\alpha i} - \bar{x}_i)(x_{\alpha j} - \bar{x}_j) \quad (i, j = 1, 2, \dots, p)$$

(3) 样本协方差阵 S : 注意

$$S = \frac{1}{n-1} A = (s_{ij})_{p \times p}$$

其中

$$s_{ii} = \frac{1}{n-1} \sum_{\alpha=1}^n (x_{\alpha i} - \bar{x}_i)^2 (i = 1, 2, \dots, p)$$

称为变量 X_i 的样本方差;

样本方差的平方根 $\sqrt{s_{ii}}$ 称为变量 X_i 的样本标准差.

(4) 样本相关阵 \hat{R} :

$$\hat{R} = (r_{ij})_{p \times p},$$

其中

$$r_{ij} = \hat{\rho}_{ij} = \frac{s_{ij}}{\sqrt{s_{ii}}\sqrt{s_{jj}}} \quad \text{or} \quad \frac{a_{ij}}{\sqrt{a_{ii}}\sqrt{a_{jj}}}$$

样本相关系数 r_{ij} 为总体相关系 ρ_{ij} 的估计.

$$\rho_{ij} = \frac{\text{Cov}(X_i, X_j)}{\sqrt{\text{Var}(X_i)\text{Var}(X_j)}}.$$

(5) 正态参数 μ, Σ 的矩估计

- 样本均值向量 \bar{X} 可作为总体均值 μ 的估计,

$$\hat{\mu} = \bar{X}.$$

- 样本协方差阵 S 可以作为总体协方差阵 Σ 的估计.

$$\hat{\Sigma} = A/n.$$

- 样本相关阵 \hat{R} 可以作为总体相关阵 R 的估计.

二、 μ, Σ 的最大似然估计

1. 似然函数

$$\begin{aligned} & L(\mu, \Sigma) \\ &= \prod_{i=1}^n \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (X_{(i)} - \mu)' \Sigma^{-1} (X_{(i)} - \mu) \right] \\ &= \frac{1}{(2\pi)^{np/2} |\Sigma|^{n/2}} \exp \left\{ \text{tr} \left[-\frac{1}{2} \Sigma^{-1} \sum_{i=1}^n (X_{(i)} - \mu)(X_{(i)} - \mu)' \right] \right\} \\ &= \frac{1}{(2\pi)^{np/2} |\Sigma|^{n/2}} \exp \left\{ \text{tr} \left[-\frac{1}{2} \Sigma^{-1} (A + n(\bar{X} - \mu)(\bar{X} - \mu)') \right] \right\}. \end{aligned}$$

2.讨论 $\ln L(\mu, \Sigma)$ 的最大值点

$$\begin{aligned}\ln L(\mu, \Sigma) &= -\frac{np}{2} \ln 2\pi - \frac{n}{2} \ln |\Sigma| \\ &\quad - \frac{1}{2} \text{tr} \left[\Sigma^{-1} \sum_{i=1}^n (X_{(i)} - \mu)(X_{(i)} - \mu)' \right] \\ &= C - \frac{1}{2} \text{tr} [\Sigma^{-1} A + n \Sigma^{-1} (\bar{X} - \mu)(\bar{X} - \mu)'] \\ &= C - \frac{1}{2} \text{tr} (\Sigma^{-1} A) - \frac{n}{2} [(\bar{X} - \mu) \Sigma^{-1} (\bar{X} - \mu)'] \\ &\leq C - \frac{1}{2} \text{tr} (\Sigma^{-1} A)\end{aligned}$$

以上等式当且仅当 $\mu = \bar{X}$ 时成立,即对于固定的 $\Sigma > 0$,有

$$\ln L(\bar{X}, \Sigma) = \max_{\mu} \ln L(\mu, \Sigma)$$

$$\begin{aligned} & \ln L(\bar{X}, \Sigma) \\ &= -\frac{np}{2} \ln 2\pi - \frac{n}{2} \ln |\Sigma| - \frac{1}{2} \text{tr}(\Sigma^{-1}A) \\ &= -\frac{np}{2} \ln 2\pi - \frac{n}{2} \left[\ln |\Sigma| + \text{tr} \left(\Sigma^{-1} \frac{A}{n} \right) \right] \\ &= C_1 - \frac{n}{2} \left[\text{tr} \left(\Sigma^{-1} \frac{A}{n} \right) - \ln \left| \Sigma^{-1} \frac{A}{n} \right| + \ln \left| \frac{A}{n} \right| \right] \\ &= C_1 - \frac{n}{2} \left[\text{tr} \left(\Sigma^{-1/2} \frac{A}{n} \Sigma^{-1/2} \right) - \ln \left| \Sigma^{-1/2} \frac{A}{n} \Sigma^{-1/2} \right| + \ln \left| \frac{A}{n} \right| \right] \\ &\leq C_1 - \frac{np}{2} - \frac{n}{2} \ln \left| \frac{A}{n} \right| \end{aligned}$$

注意到: $\ln |\Sigma| = -\ln |\Sigma^{-1}|$, 其中最后一个不等式利用引理2.5.1 (见下一页)。

引理2.5.1 设 B 为 p 阶正定矩阵, 则

$$\text{tr} B - \ln |B| > p,$$

且等号成立的充分必要条件是 $B = I_p$.

- 在本定理证明中, $B = \Sigma^{-1/2} \frac{A}{n} \Sigma^{-1/2}$ 是正定矩阵.
- 由引理2.5.1知当且仅当 $B = \Sigma^{-1/2} \frac{A}{n} \Sigma^{-1/2} = I_p$ 时等号成立, 即

$$\hat{\Sigma} = \frac{A}{n}.$$

- 似然函数的最大值是

$$L\left(\bar{X}, \frac{A}{n}\right) = \left(\frac{1}{2\pi e}\right)^{np/2} |A|^{-n/2}.$$

定理2.5.1 设 $X_{(i)}(i = 1, \cdots, n)$ 为 p 元正态总体 $N_p(\mu, \Sigma)$ 的随机样本, $n > p$, 则 μ, Σ 的最大似然估计为

$$\hat{\mu} = \overline{X}, \quad \hat{\Sigma} = \frac{1}{n} A.$$

三、最大似然估计量的性质

定理2.5.2 设 \bar{X} 和 A 分别为 p 元正态总体 $N_p(\mu, \Sigma)$ 的均值向量和样本离差阵,则

① $\bar{X} \sim N_p(\mu, \frac{1}{n}\Sigma).$

② $A \stackrel{d}{=} \sum_{t=1}^{n-1} Z_t Z_t',$

其中: Z_1, \dots, Z_{n-1} 独立同分布于 $N_p(0, \Sigma).$

③ \bar{X} 与 A 相互独立.

④ $P(A > 0) = 1 \iff n > p.$

2和3的证明

- 设 Γ 是 n 阶标准正交矩阵($\Gamma'\Gamma = \Gamma\Gamma' = I$), 具有以下形式

$$\Gamma = \begin{bmatrix} r_{11} & \cdots & r_{1n} \\ \vdots & & \vdots \\ r_{(n-1)1} & \cdots & r_{(n-1)n} \\ 1/\sqrt{n} & \cdots & 1/\sqrt{n} \end{bmatrix} = (r_{ij})_{n \times n}.$$

- 记

$$Z = \begin{bmatrix} Z'_{(1)} \\ \vdots \\ Z'_{(n)} \end{bmatrix} = \Gamma \begin{bmatrix} X'_{(1)} \\ \vdots \\ X'_{(n)} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n r_{1i} X'_{(i)} \\ \vdots \\ \sum_{i=1}^n r_{ni} X'_{(i)} \\ 1/\sqrt{n} \sum_{i=1}^n X'_{(i)} \end{bmatrix}.$$

即

$$Z_{(i)} = \sum_{j=1}^n r_{ij} X_{(j)} = (X_{(1)}, \cdots, X_{(n)}) \begin{bmatrix} r_{i1} \\ \vdots \\ r_{in} \end{bmatrix}.$$

计算得

$$E[Z_{(i)}] = E\left[\sum_{j=1}^n X_{(j)} r_{ij}\right] = \sum_{j=1}^n r_{ij} \mu = 0.$$

$$\text{Var}[Z_{(i)}] = \text{Var}\left[\sum_{j=1}^n X_{(j)} r_{ij}\right] = \sum_{j=1}^n r_{ij}^2 \Sigma = \Sigma.$$

$$\text{Cov}[Z_{(i)}, Z_{(k)}] = \sum_{j=1}^n r_{ij} r_{kj} \Sigma = 0.$$

$Z_{(i)}$ 是 p 维正态随机向量的线性组合, 因此, 仍服从正态分布.

- $Z_{(i)} \sim N_p(0, \Sigma), i = 1, \dots, n-1;$
- $Z_{(n)} = \sqrt{n}\bar{X} \sim N(\sqrt{n}\mu, \Sigma);$

由于 Γ 的正交性,

$$\begin{aligned}Z'Z &= \sum_{i=1}^n Z_{(i)}Z'_{(i)} = \sum_{i=1}^{n-1} Z_{(i)}Z'_{(i)} + Z_{(n)}Z'_{(n)}, \\Z'Z &= X'\Gamma' \cdot \Gamma X = X'X, \\X'X &= \sum_{i=1}^n X_{(i)}X'_{(i)}.\end{aligned}$$

- 由此可得(2),

$$\sum_{i=1}^{n-1} Z_{(i)} Z'_{(i)} = \sum_{i=1}^n X_{(i)} X'_{(i)} - Z_{(n)} Z'_{(n)} = \sum_{i=1}^n X_{(i)} X'_{(i)} - n \bar{X} \bar{X}' = A.$$

离差阵 A 可以表示如下,

$$A = \sum_{i=1}^{n-1} Z_{(i)} Z'_{(i)}.$$

- 因为 $Z_{(i)}$ 是独立的, 因此, $Z_{(n)} = \sqrt{n} \bar{X}$ 与 A 独立, 即得(3).

4.证明 由上面知 $A = \sum_{i=1}^{n-1} Z_{(i)} Z'_{(i)} \triangleq BB'$, B 为 $p \times n - 1$ 的矩阵.

- $\Pr(A > 0) = 1 \Rightarrow n > p$.

A a.s 为正定矩阵, 则 A 的秩是 p , $B_{p \times n-1}$ 的秩也为 p ,

即 $p \leq n - 1$, 或 $p < n$.

- $n > p \Rightarrow \Pr(A > 0) = 1$. 只要证明

$$\Pr(B \text{ 的前 } p \text{ 列为线性相关}) = 0.$$

(下面续)

$p < n$, 则有 $p \leq n - 1$.

- (1) $A = BB'$, 其中矩阵 $B = (Z_{(1)}, \cdots, Z_{(n-1)})$. $R(B) = p$.
- (2) 前 p 列为独立同分布, 服从正态分布的随机向量.
- (3) 由正态分布的性质知 $Z_{(1)}, \cdots, Z_{(p)}$ 的线性组合也服从正态分布, 即对于任意非零的向量 $(\beta_1, \cdots, \beta_p)$,

$$\sum_{i=1}^p \beta_i Z_{(i)} \sim \text{正态分布}.$$

- (4) 由 $\sum_{i=1}^p \beta_i Z_{(i)}$ 为正态分布, 因此,

$$\Pr \left(\sum_{i=1}^p \beta_i Z_{(i)} = 0 \right) = 0 \Rightarrow (Z_{(1)}, \cdots, Z_{(p)}) \text{ 线性无关}.$$

统计意义下线性无关.

μ 和 Σ 的估计所具有的一些性质.

- ① 无偏性 $E[\bar{X}] = \mu$, $E[S] = \frac{1}{n-1}E[A] = \Sigma$.
- ② \bar{X} 和 $S(\hat{\Sigma})$ 是充分统计量.
- ③ 可以证明 \bar{X} 和 $\hat{\Sigma}$ 是极大极小估计.
- ④ 利用大数定理证明相合性.
- ⑤ 可以证明渐近正态性.
- ⑥ 其他

四、函数参数的最大似然估计 设参数向量 θ 的变化范围

是 $\Theta \in \mathbb{R}_k$, $L(\Theta)$ 是似然函数. 设 $w = g(\theta)$ 是 Θ 到 Θ^* 的Borel 可测映射, 这里 Θ^* 是 \mathbb{R}_k 的子集.

对任何 $w \in \Theta^*$, 令

$$M(w) = \sup_{\theta: g(\theta)=w} L(\theta).$$

定义2.5.1 称 $M(w)$ 为函数 $g(\theta)$ 诱导出似然函数.

定义2.5.2 若 \hat{w} 满足 $M(\hat{w}) = \sup_w M(w)$, 则称 \hat{w} 是 $g(\theta)$ 的最大似然估计.

定理2.5.3 若 $\hat{\theta}$ 是 θ 的最大似然估计, 则 $\hat{w} = g(\hat{\theta})$ 是 $g(\theta)$ 的最大似然估计.

例2.5.1 设 $X = (X_1, X_2, \dots, X_p)' \sim N_p(\mu, \Sigma)$, X_i, X_j 的相关系数

$$\rho_{ij} = \frac{\sigma_{ij}}{\sqrt{\sigma_{ii}}\sqrt{\sigma_{jj}}}$$

的最大似然估计为

$$r_{ij} = \frac{a_{ij}}{\sqrt{a_{ii}}\sqrt{a_{jj}}}$$

其中: a_{ij} 为离差阵 A 的第 i 行, 第 j 列的元素.

例2.5.2 设

$$X = \begin{bmatrix} X^{(1)} \\ X^{(2)} \end{bmatrix} \sim N_p \left(\begin{bmatrix} \mu^{(1)} \\ \mu^{(2)} \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right)$$

则 $X^{(1)}$ 对 $X^{(2)}$ 的回归系数阵 $B = \Sigma_{12}\Sigma_{22}^{-1}$ 的极大似然估计为

$$\hat{B} = \hat{\Sigma}_{12}\hat{\Sigma}_{22}^{-1} = A_{12}A_{22}^{-1}$$

及 $X^{(2)}$ 给定时 $X^{(1)}$ 的条件协方差阵 $\Sigma_{11 \cdot 2}$ 的极大似然估计量为

$$\hat{\Sigma}_{11 \cdot 2} = \frac{1}{n}(A_{11} - A_{12}A_{22}^{-1}A_{21}).$$

Definition The random vector \mathbf{X} is said to have an elliptical distribution with parameters μ and Σ if its characteristic function can be expressed as

$$\mathbb{E}[\exp(it'\mathbf{X})] = \exp(it'\mu)\phi(t'\Sigma t),$$

for some function $\phi : \mathbb{R} \rightarrow \mathbb{R}$ and where Σ is given by

$$\Sigma = AA'$$

for some $n \times m$ matrix A . $\mathbf{X} \sim \text{Ell}_n(\mu, \Sigma, \phi)$.

Property 1

An n -dimensional random vector \mathbf{X} has $Ell_n(\mu, \Sigma, \phi)$ distribution if, and only if, for any vector $\alpha \in \mathbb{R}^n$, one has

$$\alpha' \mathbf{X} \sim Ell_1(\alpha' \mu, \alpha' \Sigma \alpha, \phi)$$

Property 2 For $k = 1, \dots, n$,

$$X_k \sim Ell_1(\mu_k, \sigma_k^2, \phi)$$

Let

$$S = \sum_{k=1}^n X_k = \mathbf{e}'\mathbf{X}$$

where $\mathbf{e} = (1, \dots, 1)$, it follows that

$$\mathbf{X} \sim Ell_n(\mu, \Sigma, \phi) \Rightarrow Ell_1(\mathbf{e}'\mu, \mathbf{e}'\Sigma\mathbf{e}, \phi)$$

where $\mathbf{e}'\mu = \sum_{k=1}^n \mu_k$ and $\mathbf{e}'\Sigma\mathbf{e} = \sum_{k=1}^n \sum_{l=1}^n \sigma_{kl}$.

Property 3 For any $m \times n$ matrix \mathbf{B} , any vector $\mathbf{c} \in \mathbb{R}^m$ and random vector $\mathbf{X} \sim Ell_n(\mu, \Sigma, \phi)$, we have

$$\mathbf{B}\mathbf{X} + \mathbf{c} \sim Ell_n(\mathbf{B}\mu + \mathbf{c}, \mathbf{B}\Sigma\mathbf{B}', \phi).$$

An elliptically distributed random vector $\mathbf{X} \sim Ell_n(\mu, \Sigma, \phi)$. A necessary condition for \mathbf{X} to have a density is that $\text{rank}(\Sigma) = n$. If $\mathbf{X} \sim Ell_n(\mu, \Sigma, \phi)$ has a density, then it will be of the form

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{c}{\sqrt{|\Sigma|}} g((\mathbf{x} - \mu)' \Sigma^{-1} (\mathbf{x} - \mu)).$$

- $g_n(u) = \exp(-u/2)$, $c_n = (2\pi)^{-n/2} \Rightarrow \mathbf{X} \sim N_n(\mu, \Sigma)$.
- $g_n(u) = \left(1 + \frac{u}{m}\right)^{(n+m)/2}$, $c_n = \frac{\Gamma((n+m)/2)}{(m\pi)^{n/2} \Gamma(m/2)} \Rightarrow t_n^m(\mu, \Sigma)$.

Some families of elliptical distributions with their characteristic generator and/or density generator.

- Cauchy, $g_n(u) = (1 + u)^{-(n+1)/2}$;
- Exponential power, $g_n(u) = \exp(-ru^s)$, $r, s > 0$;
- Laplace, $g_n(u) = \exp(-|u|)$;
- Logistic, $g_n(u) = \frac{\exp(-u)}{(1+\exp(-u))^2}$;
- Normal, $g_n(u) = \exp(-u/2)$;
- Stable laws, $\phi(u) = \exp(-ru^{s/2})$, $0 < s \leq 2$, $r > 0$;
- Student, $g_n(u) = (1 + \frac{u}{m})^{(n+m)/2}$, $m > 0$ an integer.